SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Sveučilišni diplomski studij Računarstvo, podatkovne znanosti

KLASIFIKACIJA TIPOVA TKIVA KORIŠTENJEM RESNET I EFFICIENTNET ARHITEKTURA

Obrada slike i računalni vid

Marinela Bekić

Osijek, 2026.

SADRŽAJ

1. UVOD 2

2. DUBOKO UČENJE U ANALIZI HISTOLOŠKIH SLIKA 4

2.1. Duboko učenje 4

2.2. Konvolucijske neuronske mreže 5

2.3. Analiza medicinskih i histoloških slika 7

2.4. Izazovi u medicinskoj klasifikaciji slika 8

3. KONVOLUCIJSKE ARHITEKTURE RESNET I EFFICIENTNET 10

3.1. ResNet arhitektura 10

3.2. EfficientNet arhitektura 11

3.3. Usporedba ResNet i EfficientNet 13

4. PRIJENOS ZNANJA U MEDICINSKOJ KLASIFIKACIJI SLIKA 14

4.1. Transfer learning 14

4.2. Pretrenirani modeli 15

4.3. Prednosti u medicinskim primjenama 16

5. EKSPERIMENTALNA ANALIZA I REZULTATI 17

5.1. Opis skupa podataka 17

5.2. Implementacija modela 19

5.3. Analiza učinkovitosti 19

6. ZAKLJUČAK 22

7. LITERATURA 23

1. UVOD

Histološka analiza tkiva jedna je od važnih metoda u medicinskoj dijagnostici, a posebno u otkrivanju i klasifikaciji različitih bolesti, uključujući i maligne promjene tkiva. Histopatološke slike dobivaju se mikroskopskom analizom uzoraka tkiva, pri čemu je moguće detaljno promatrati strukturu stanica i tkiva. No, ručna analiza takvih slika zahtijeva veliko iskustvo i stručnost patologa te često može biti dugotrajan i u nekoj mjeri subjektivan proces. Upravo zbog toga posljednjih godina sve se više razvijaju računalni sustavi koji mogu pomoći u automatskoj analizi i klasifikaciji histoloških slika, a primjena takvih metoda omogućuje bržu obradu velikog broja medicinskih slika te može doprinijeti većoj pouzdanosti i dosljednosti u donošenju dijagnostičkih odluka [1].

Razvoj metoda dubokog učenja (engl. *deep learning*) značajno je poboljšalo područje analize medicinskih slika. Duboki modeli, a posebno konvolucijske neuronske mreže (engl. *Convolutional Neural Network*, CNN), pokazali su vrlo dobre rezultate u zadacima prepoznavanja uzoraka i klasifikacije slika. Za razliku od tradicionalnih metoda strojnog učenja, koje često zahtijevaju ručno definiranje značajki, modeli dubokog učenja mogu automatski učiti relevantne značajke iz samih podataka. Ova sposobnost učenja složenih reprezentacija podataka čini duboko učenje posebno pogodnim za analizu kompleksnih medicinskih slika, poput histopatoloških uzoraka [2]. U području analize histoloških slika konvolucijske neuronske mreže koriste se za različite zadatke, poput klasifikacije tipova tkiva, detekcije patoloških promjena i segmentacije stanica. Moderni modeli dubokog učenja, kao što su ResNet i EfficientNet, pokazali su visoku učinkovitost u obradi medicinskih slika, a to je ponajviše zbog njihove sposobnosti učenja hijerarhijskih reprezentacija podataka te učinkovite obrade velikih količina slika, a posebno su se pokazali korisnima u klasifikaciji histopatoloških slika, gdje razlike između pojedinih klasa često mogu biti vrlo suptilne i teško uočljive [3].

No, unatoč značajnom napretku u primjeni dubokog učenja, analiza medicinskih slika i dalje ostaje izazovno područje istraživanja, a jedan od glavnih problema je relativno mali broj dostupnih označenih medicinskih skupova podataka, što zapravo i otežava treniranje dubokih modela te se zbog toga u praksi često primjenjuje tehnika prijenosa podataka (engl. *transfer learning*), pri kojem se modeli prethodno trenirani na velikim skupovima podataka, poput *ImageNet*-a, prilagođavaju posebnim medicinskim zadacima. Ovaj pristup omogućuje bržu konvergenciju modela, bolju sposobnost generalizacije te smanjenje rizika od prenaučenosti (engl. *overfitting*) [4], [5].

Cilj ovog rada je istražiti primjenu dubokog učenja u klasifikaciji histoloških slika korištenjem konvolucijskih neuronskih mreža. U eksperimentalnom dijelu implementirana su dva modela dubokog učenja, ResNet18 i EfficientNet-B0, koji su trenirani na skupu podataka MHIST (*Minimalist Histopathology Image Dataset*) [6]. Performanse modela uspoređene su prema nekoliko kriterija, uključujući točnost klasifikacije, F1-score, brzinu treniranja, broj parametara i memorijske zahtjeve.

Struktura rada je organizirana na slijedeći način; u drugom su poglavlju predstavljene osnovne teorijske osnove dubokog učenja i konvolucijskih neuronskih mreža te sama njihova primjena u analizi medicinskih i histoloških slika. Treće poglavlje opisuje arhitekture ResNet i EfficientNet modela te njihovu međusobnu usporedbu. U četvrtom je poglavlju objašnjen koncept t*ransfer learning* te njegova primjena u medicinskoj klasifikaciji slika. Peto poglavlje prikazuje eksperimentalni dio rada, uključujući opis skupa, implementaciju modela te analizu dobivenih rezultata, a na samom kraju rada su doneseni zaključci i prijedlozi za daljnja istraživanja.

2. DUBOKO UČENJE U ANALIZI HISTOLOŠKIH SLIKA

Razvoj umjetne inteligencije i strojnog učenja u velikoj je mjeri poboljšao analizu medicinskih slika, a posebno se ističe duboko učenje koje omogućuje automatsko prepoznavanje složenih uzoraka u velikim skupovima podataka. Duboko učenje koristi višeslojne neuronske mreže koje uče hijerarhijske reprezentacije, niži slojevi prepoznaju jednostavne značajke, dok viši slojevi hvataju složenije obrasce [2].

U medicini, duboko učenje pokazuje dobre rezultate u obradi različitih vrsta slika, uključujući radiološke snimke i histopatološke preparate. Histološke slike sadrže puno informacija o strukturi tkiva i stanica, te njihova analiza zahtijeva veliko iskustvo stručnjaka. Sustavi temeljeni na dubokom učenju mogu pomoći u automatizaciji ove analize, kako bi se smanjila subjektivnost te ubrzao dijagnostički proces [1].

Posljednjih godina duboko učenje postaje sve važnije u medicinskoj analizi slika. Korištenjem dubokih neuronskih mreža moguće je precizno klasificirati histopatološke uzorke, detektirati abnormalne stanice i segmentirati tkivo. Zahvaljujući sposobnosti učenja složenih vizualnih značajki, ovi modeli često nadmašuju tradicionalne metode strojnog učenja koje se oslanjaju na ručno definirane značajke [3].

2.1. Duboko učenje

Duboko učenje predstavlja podskup strojnog učenja koji se temelji na umjetnim neuronskim mrežama s više skrivenih slojeva. Navedene mreže oponašaju način na koji ljudski mozak obrađuje informacije, pri čemu svaki sloj mreže obrađuje ulazne podatke i prosljeđuje rezultate sljedećem sloju te na taj način mreža postupno uči sve složenije reprezentacije podataka [4]. Na slici 1 se nalazi prikaz dubokog učenja.

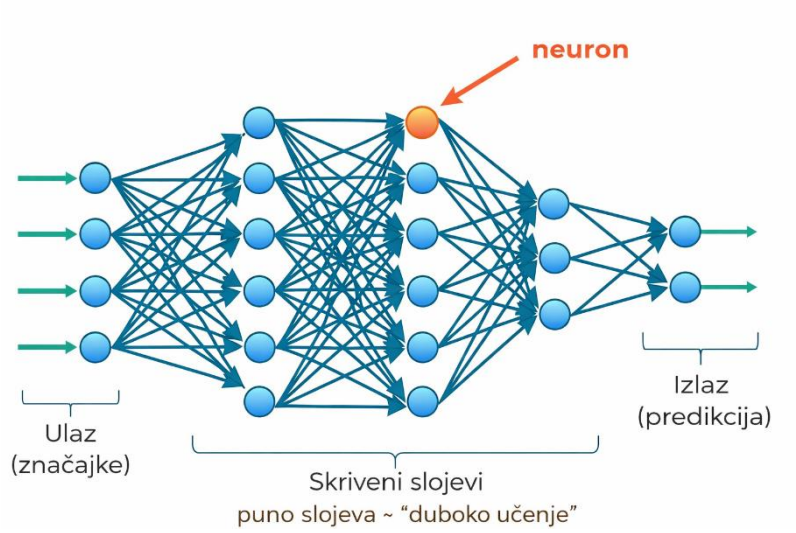

Slika 1 Prikaz dubokog učenja s neuronima

Osnovna ideja dubokog učenja je omogućiti modelu da samostalno uči značajke iz podataka bez potrebe za samim ručnim definiranjem karakteristika. U standardnim metodama strojnog učenja istraživači su morali ručno definirati značajke koje opisuju podatke, što je često zahtijevalo veliko domensko znanje, a duboko učenje upravo eliminira taj korak jer neuronske mreže automatski uče relevantne značajke tijekom procesa treniranja [5].

Jedna od glavnih prednosti dubokog učenja je to što mreže mogu učiti hijerarhijske reprezentacije podataka. Niži slojevi neuronske mreže obično prepoznaju jednostavne značajke, poput rubova, linija ili tekstura, dok viši slojevi te značajke kombiniraju u složenije obrasce i strukture. Takva hijerarhijska organizacija omogućuje modelima dubokog učenja da učinkovito prepoznaju složene uzorke u slikama, zvuku i tekstu [7].

Zahvaljujući ovim sposobnostima, duboko učenje se pokazalo vrlo uspješnim u zadacima prepoznavanja uzoraka, a osobito u analizi slika. U medicinskoj dijagnostici duboki modeli omogućuju automatiziranu klasifikaciju medicinskih slika, otkrivanje abnormalnosti i analizu složenih struktura tkiva, a upravo zbog tih mogućnosti duboko učenje danas predstavlja jednu od najvažnijih tehnologija u razvoju inteligentnih sustava za medicinsku analizu podataka [2].

2.2. Konvolucijske neuronske mreže

Konvolucijske neuronske mreže (engl. *Convolutional Neural Networks*, CNN) predstavljaju posebnu vrstu dubokih neuronskih mreža koje su posebno prilagođene za obradu slikovnih podataka. Za razliku od klasičnih potpuno povezanih neuronskih mreža, CNN modeli koriste konvolucijske operacije koje omogućuju učinkovito prepoznavanje prostornih obrazaca u slikama. Upravo zbog te sposobnosti konvolucijske mreže postale su standardna metoda u zadacima

računalnog vida, uključujući klasifikaciju, detekciju objekata i segmentaciju slika [2]. Na slici 2 se nalazi primjer arhitekure konvolucijske neuronske mreže.

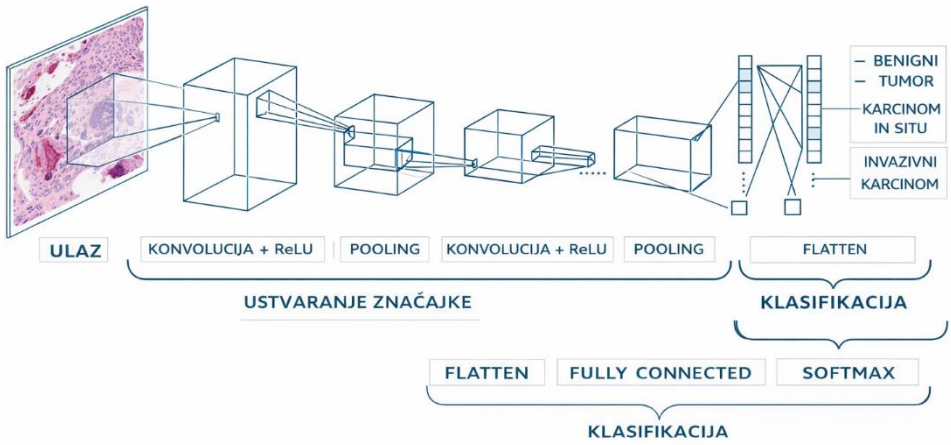

Slika 2 Arhitektura konvolucijske neuronske mreže

Osnovni princip rada konvolucijskih neuronskih mreža zasniva se na primjeni konvolucijskih filtara (kernela) na ulaznu sliku. Filtar prolazi preko slike i izračunava lokalne značajke, poput rubova, tekstura ili drugih vizualnih struktura, a rezultat ove operacije je *feature* mapa, koja predstavlja aktivacije neurona za određeni filtar. Pri korištenju većeg broja filtara, mreža može prepoznati različite karakteristike slike te na taj način stvoriti detaljnu reprezentaciju ulaznih podataka [3].

CNN arhitekture se obično sastoje od nekoliko osnovnih vrsta slojeva. Konvolucijski slojevi služe za izdvajanje značajki iz slike pomoću različitih filtara. Nakon njih se često primjenjuju aktivacijske funkcije, poput ReLU funkcije, koje uvode nelinearnost u model i omogućuju mu učenje složenijih obrazaca. Osim toga, koriste se *pooling* slojevi, koji smanjuju dimenzionalnost *feature* mapa, čime se zapravo i smanjuje računalna složenost modela te povećava njegova otpornost na manje promjene u slici [4]. Na kraju konvolucijskog dijela mreže obično se nalaze potpuno povezani slojevi (engl. *fully connected layers*) koji koriste značajke naučene u prethodnim slojevima za konačnu klasifikaciju slike. Ti slojevi kombiniraju informacije iz cijele mreže te na temelju toga generiraju izlazne vrijednosti koje predstavljaju vjerojatnost da slika pripada određenoj klasi.

Konvolucijske neuronske mreže su posebno pogodne za analizu slika jer učinkovito koriste prostornu strukturu podataka. Za razliku od tradicionalnih metoda, CNN modeli sami uče relevantne značajke iz podataka, bez potrebe da ih netko ručno definira. Zahvaljujući tome,

uspješno se primjenjuju u raznim područjima računalnog vida, uključujući i medicinsku analizu slika [1].

U području histopatološke analize, CNN modeli mogu prepoznati složene teksture tkiva i nenametljive razlike između različitih tipova stanica, što omogućuje automatiziranu klasifikaciju histoloških uzoraka i može povećati preciznost te učinkovitost medicinske dijagnostike. Zbog navedenih prednosti, konvolucijske neuronske mreže danas čine temelj mnogih modernih sustava za analizu medicinskih slika [7].

2.3. Analiza medicinskih i histoloških slika

Medicinske su slike važan izvor informacija u dijagnostici različitih bolesti, a posebno mjesto zauzimaju histološke slike, koje se dobivaju mikroskopskom analizom uzoraka tkiva. Histopatološka analiza omogućuje detaljno proučavanje strukture stanica i tkiva te je ključna za otkrivanje mnogih bolesti, uključujući različite vrste tumora i druge patološke promjene [1]. Na slici 3 je prikazan primjer histopatološke slike iz skupa podataka MHIST.

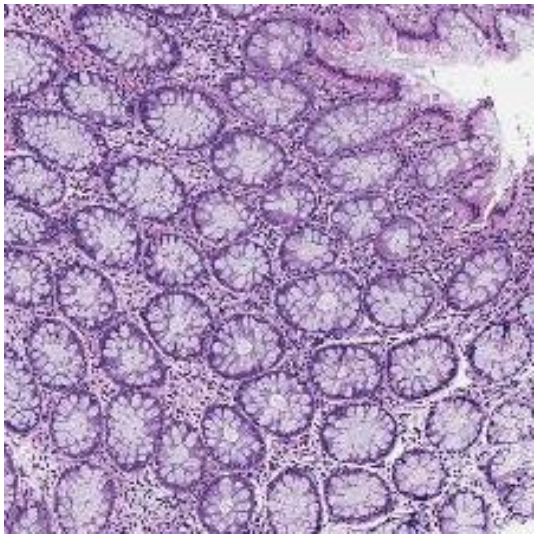

Slika 3 Primjer iz skupa podataka MHIST

Histološke slike karakterizira velika složenost i bogata teksturalna struktura. Uzorci tkiva najčešće se pripremaju posebnim metodama bojenja, poput *hematoksilin-eozin* (H&E) bojenja, što omogućuje jasnije razlikovanje različitih struktura stanica i tkiva. No, zbog varijacija u pripremi uzoraka, načinu bojenja i kvaliteti mikroskopskih snimaka, slike mogu značajno varirati, što može otežati njihovu analizu [3].

Posljednjih nekoliko godina razvijeni su brojni računalni sustavi za automatsku analizu histopatoloških slika, a ti sustavi koriste metode strojnog i dubokog učenja kako bi identificirali i klasificirali različite tipove tkiva ili patoloških promjena. U tom kontekstu konvolucijske

neuronske mreže (CNN) pokazale su se posebno učinkovitim jer mogu automatski učiti kompleksne vizualne značajke koje su često teško uočljive ljudskom oku [2].

U analizi medicinskih slika obično se koriste tri osnovna zadatka, a to su: klasifikacija, detekcija i segmentacija. Klasifikacija podrazumijeva određivanje kojoj kategoriji pripada slika ili regija slike, detekcija pronalazi specifične strukture ili abnormalnosti, dok segmentacija omogućuje precizno izdvajanje pojedinih dijelova tkiva ili stanica. U ovom radu naglasak je na klasifikaciji histoloških slika, odnosno određivanju pripadnosti uzorka određenoj klasi tkiva [4].

Primjena dubokog učenja u analizi histopatoloških slika omogućuje automatizaciju procesa koji je tradicionalno zahtijevao ručnu analizu stručnjaka. Time se povećava učinkovitost dijagnostičkog procesa te smanjuje opterećenje samih liječnika, dok računalni sustavi služe kao pomoćni alat u donošenju medicinskih odluka. Zbog toga je istraživanje metoda dubokog učenja za analizu histoloških slika postalo jedno od ključnih područja razvoja medicinske umjetne inteligencije [5].

2.4. Izazovi u medicinskoj klasifikaciji slika

Iako su metode dubokog učenja znatno unaprijedile analizu medicinskih slika, njihova primjena u dijagnostici i dalje se suočava s brojnim izazovima. Jedan od glavnih problema je ograničena dostupnost kvalitetnih označenih medicinskih skupova podataka. Za razliku od općih skupova podataka koji mogu sadržavati milijune slika, medicinski skupovi podataka su često mali jer njihovo označavanje zahtijeva stručnjake poput liječnika ili patologa te zbog toga treniranje dubokih modela „od nule“ može biti otežano i dovesti do prenaučenosti [4]. Drugi čest problem je neuravnoteženost klasa (engl. *class imbalance*). U mnogim medicinskim zadacima broj primjera jedne klase može biti znatno veći od druge, što može negativno utjecati na performanse modela jer postaje skloniji predviđanju dominantne klase. U analizi histopatoloških slika ovo se često događa jer određeni tipovi tkiva ili patoloških promjena mogu biti rjeđi [2].

Dodatni izazov je velika varijabilnost histoloških uzoraka, odnosno slike mogu značajno varirati ovisno o načinu pripreme uzorka, korištenoj metodi bojenja, kvaliteti mikroskopske snimke i individualnim razlikama između pacijenata. Takve varijacije otežavaju učenje modela jer isti tip tkiva može imati različite vizualne karakteristike u različitim uzorcima [3]. Osim tehničkih izazova, primjena umjetne inteligencije u medicini uključuje i etičke i kliničke aspekte. Na primjer, sustavi temeljeni na umjetnoj inteligenciji ne mogu potpuno zamijeniti medicinske stručnjake, već trebaju biti pomoćni alat u donošenju odluka, a važno je i osigurati transparentnost i pouzdanost modela kako bi se smanjio rizik pogrešnih dijagnostičkih zaključaka [5].

Unatoč svemu, metode dubokog učenja imaju veliki potencijal za poboljšanje analize medicinskih slika. Kombinacija naprednih arhitektura neuronskih mreža, većih skupova podataka i tehnika poput *transfer learning*-a omogućuje razvoj sustava koji mogu postići visoku točnost u medicinskoj klasifikaciji. Zbog navedenog, istraživanja u ovom području i dalje imaju važnu ulogu u razvoju inteligentnih medicinskih sustava [1].

3. KONVOLUCIJSKE ARHITEKTURE RESNET I EFFICIENTNET

Razvoj konvolucijskih neuronskih mreža doveo je do pojave raznih naprednijih arhitektura koje omogućuju bolju i učinkovitiju analizu slikovnih podataka, a jedni od najpoznatijih u području računalnog vida su ResNet (engl. *Residual Network*) i EfficientNet. Navedene arhitekture su razvijene kako bi se poboljšale performanse dubokih neuronskih mreža, ali i omogućilo treniranje dubljih i složenijih modela bez prevelikog povećanja računalnih zahtjeva. Općenito, modeli dubokog učenja često daju bolje rezultate kada imaju više slojeva, jer tada mogu naučiti složenije obrasce u podacima. No, povećanje dubine mreže donosi i određene probleme, poput nestajanja gradijenta (engl. *vanishing gradient*) i otežanog treniranja te su upravo zbog toga razvijene različite arhitekture koje pokušavaju ublažiti navedene probleme i omogućiti stabilnije učenje. ResNet je uveden kako bi riješio problem nestajanja gradijenta pomoću rezidualnih veza (engl. *skip connections*) koje omogućuju lakši protok informacija kroz mrežu, dok se EfficientNet fokusira na optimizaciju odnosa između točnosti i složenosti modela, koristeći metodu kompaund skaliranja (engl. *compound scaling*), gdje se istovremeno povećavaju dubina, širina i rezolucija mreže [3].

Zbog svojih rješenja, ResNet i EfficientNet postižu vrlo dobre rezultate u različitim zadacima računalnog vida, uključujući i klasifikaciju medicinskih i histopatoloških slika te se upravo zbog toga često koriste u istraživanjima koja se bave primjenom dubokog učenja u medicinskoj dijagnostici [7], [8].

3.1. ResNet arhitektura

Arhitektura ResNet predstavljena je kako bi se riješio problem treniranja vrlo dubokih neuronskih mreža. Naime, dok tradicionalnih dubokih mreža povećanje broja slojeva često dovodi do problema nestajanja gradijenta što može uzrokovati da tijekom procesa treniranja gradijenti postaju vrlo mali te se težine u ranijim slojevima mreže teško ažuriraju, a posljedica toga može biti otežano ili vrlo sporo učenje modela [3], [9].

Kako bi se navedeni problem riješio, ResNet uvodi koncept rezidualnog učenja (engl. *residual learning*) te umjesto da mreža pokušava naučiti izravnu funkciju preslikavanja između ulaza i izlaza, model uči rezidualnu funkciju, odnosno razliku između ulazne vrijednosti i željenog izlaza. Ova je ideja implementirana pomoću rezidualnih veza koje omogućuju da se ulaz iz jednog sloja direktno proslijedi nekoliko slojeva dalje unutar mreže. U običajnom rezidualnom bloku ulazni signal prolazi kroz nekoliko konvolucijskih slojeva, a nakon toga se rezultat tih operacija zbraja s

originalnim ulazom te na taj način mreža može lakše učiti potrebne transformacije jer informacija iz ranijih slojeva može izravno utjecati na kasnije slojeve mreže. Navedena struktura omogućuje stabilnije treniranje dubokih modela te smanjuje problem nestajanja gradijenta [2], [9]. Na slici 4 je prikazana arhitektura ResNet modela.

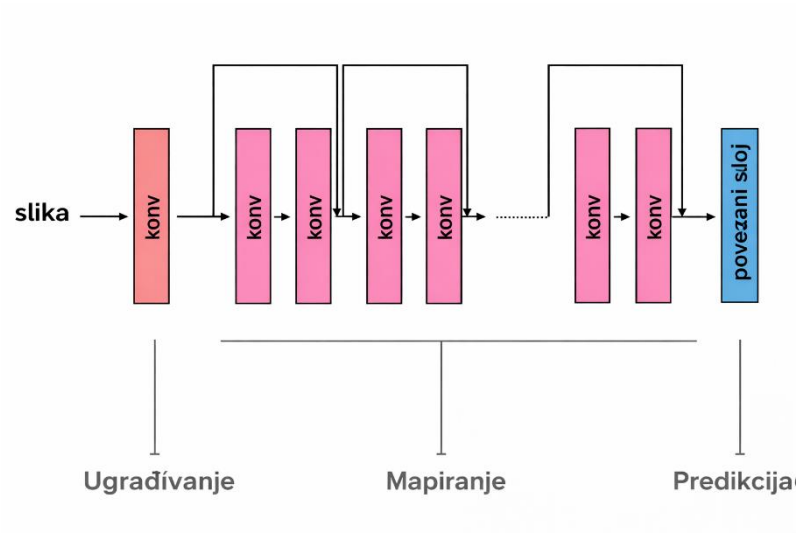

Slika 4 Arhitektura ResNet

ResNet arhitektura se sastoji od niza rezidualnih blokova koji uključuju konvolucijske slojeve, normalizacijske slojeve i aktivacijske funkcije. Postoji više varijanti ResNet modela, a one se razlikuju po broju slojeva, primjerice ResNet18, ResNet34, ResNet50 i ResNet101 [9]. Veći broj slojeva omogućuje modelu učenje složenijih značajki, ali istovremeno povećava i računalnu složenost modela. U području analize medicinskih slika ResNet modeli često se koriste kao osnovni ili referentni modeli zbog svoje stabilnosti i dobre sposobnosti generalizacije, a posebno su se pokazali učinkovitim u zadacima klasifikacije histopatoloških slika gdje je potrebno prepoznati vrlo suptilne razlike između različitih tipova tkiva [7], [8].

3.2. EfficientNet arhitektura

Arhitektura EfficientNet razvijena je kako bi se poboljšanja učinkovitosti dubokih neuronskih mreža u zadacima računalnog vida, a za razliku od tradicionalnih pristupa u kojima se performanse modela povećavaju jednostavnim dodavanjem više slojeva ili povećanjem veličine mreže, EfficientNet uvodi pristup poznat kao kompaund skaliranje. Navedena metoda omogućuje istovremeno i uravnoteženo povećavanje dubine mreže, širine mreže i rezolucije ulaznih slika, a time se postiže bolji odnos između točnosti modela i njegove računalne složenosti [7]. U standardnim konvolucijskim mrežama povećanje performansi često se postiže povećanjem broja slojeva ili broja neurona u mreži. No, takav pristup može dovesti do značajnog povećanja broja

parametara i računalnih zahtjeva modela. EfficientNet rješava ovaj problem primjenom optimiziranog skaliranja svih dimenzija mreže istovremeno te na taj način model može postići visoku točnost uz prilično mali broj parametara [8], [10]. Na slici 5 je prikazana arhitektura EfficientNet modela.

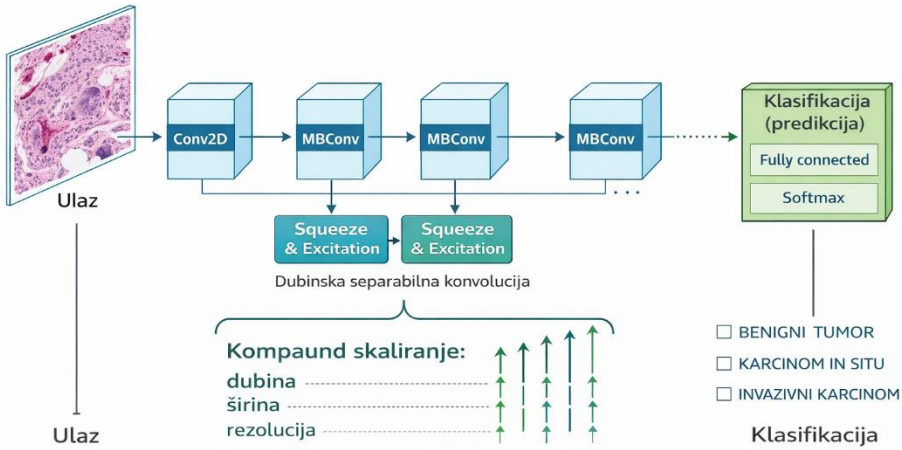

Slika 5 Arhitektura EfficientNet

EfficientNet modeli se temelje na arhitekturi *Mobile Inverted Bottleneck Convolution* (MBConv) blokova koji su početno razvijeni za mobilne i energetski učinkovite modele dubokog učenja. Navedeni blokovi koriste *depthwise separable* konvolucije koje smanjuju broj potrebnih operacija i omogućuju učinkovitiju obradu podataka. Također, EfficientNet arhitektura uključuje i *squeeze-and-excitation* mehanizam koji omogućuje modelu da dinamički prilagođava važnost pojedinih kanala značajki tijekom učenja [3]. Postoji nekoliko verzija EfficientNet modela koje se razlikuju po veličini i složenosti, od EfficientNet-B0 do EfficientNet-B7. Osnovni model, odnosno EfficientNet-B0, predstavlja početnu arhitekturu na temelju koje se primjenjuje *compound scaling* za dobivanje većih modela, a upravo zbog svoje prilično male složenosti i dobre ravnoteže između performansi i računalnih zahtjeva, EfficientNet-B0 često se koristi u istraživanjima i primjenama gdje su računalni resursi ograničeni [10].

U području analize medicinskih i histopatoloških slika EfficientNet modeli pokazali su vrlo dobre rezultate jer mogu učinkovito prepoznati kompleksne teksture i strukture tkiva uz prilično mali broj parametara te su zbog toga EfficientNet modeli često korišteni u zadacima klasifikacije medicinskih slika, gdje je potrebno postići visoku točnost uz ograničene količine podataka [7], [8].

3.3. Usporedba ResNet i EfficientNet

ResNet i EfficientNet predstavljaju dva različita pristupa poboljšanju performansi dubokih konvolucijskih neuronskih mreža. Iako obje arhitekture imaju isti cilj, povećati točnost modela u zadacima računalnog vida, način na koji to postižu prilično se razlikuje.

Kod ResNet arhitekture najvažnija ideja je uvođenje rezidualnih veza koje omogućuju da se informacije „preskaču“ između slojeva, odnosno da se lakše prenose kroz mrežu. Time se smanjuje problem nestajanja gradijenta i omogućuje treniranje jako dubokih mreža te zbog toga ResNet modeli mogu imati velik broj slojeva i pritom i dalje uspješno učiti složene obrasce u podacima [3], dok se EfficientNet fokusira na optimizaciju odnosa između performansi modela i njegove složenosti. Umjesto da se povećava samo jedna dimenzija mreže (npr. dubina), koristi se kompaund skaliranje, što znači da se istovremeno povećavaju dubina, širina i rezolucija ulaznih slika. Na taj način model može postići visoku točnost, ali bez prevelikog povećanja broja parametara i računalnih zahtjeva [7].

U usporedbi s ResNet modelima, EfficientNet arhitekture često postižu bolje performanse uz manji broj parametara što je posebno važno u primjenama gdje su računalni resursi ograničeni ili gdje je potrebno trenirati modele na prilično manjim skupovima podataka. EfficientNet modeli također koriste napredne konvolucijske blokove poput MBConv slojeva i *squeeze-and-excitation* mehanizma koji zapravo dodatno poboljšavaju sposobnost modela za filtraciju značajki iz slika [3].

U području analize medicinskih slika obje arhitekture imaju svoje prednosti. ResNet se često koristi kao neka vrsta stabilnog referentnog modela jer je pouzdan i dobro funkcionira i kod vrlo dubokih mreža, a EfficientNet nudi bolji omjer između točnosti i računalne učinkovitosti, što ga čini dobrim izborom kada treba obraditi veće količine podataka. Zbog navedenih karakteristika obje arhitekture se često koriste u istraživanja klasifikacije histopatoloških slika, a u ovom su radu odabrani modeli ResNet18 i EfficientNet-B0 kao predstavnici navedenih pristupa kako bi se mogla napraviti usporedba njihovih performansi u zadatku klasifikacije histoloških slika.

4. PRIJENOS ZNANJA U MEDICINSKOJ KLASIFIKACIJI SLIKA

U području dubokog učenja treniranje dubokih neuronskih mreža obično zahtijeva velike količine podataka i značajne količine računalnih resursa što u medicinskim primjenama to često predstavlja problem jer su dostupni skupovi podataka relativno mali. Razlog tome je što prikupljanje i označavanje medicinskih podataka zahtijeva uključivanje stručnjaka, poput liječnika i patologa, što cijeli proces čini sporijim i zahtjevnijim te treniranje modela od samog početka može biti otežano što može dovesti do problema poput prenaučenosti modela ili slabije generalizacije [4].

S ciljem rješavanja ovog problema, u mnogim se istraživanjima koristi pristup poznat kao *transfer learning* čija je ideja da se znanje koje je model već naučio na jednom velikom skupu podataka iskoristi za neki drugi, slični zadatak. U području analize medicinskih slika to obično znači da se model prvo trenira na velikim skupovima podataka općih slika, poput *ImageNet* skupova podataka koji sadrži milijune označenih primjera te se nakon toga taj isti model dodatno prilagođava konkretnom zadatku kao što je na primjer klasifikacije histoloških slika [5].

Transfer learning se pokazao jako korisnim u medicinskoj analizi slika jer omogućuje treniranje modela i kada nema puno dostupnih podataka. S obzirom da model već ima neko osnovno znanje o prepoznavanju značajki na slikama, brže uči novi zadatak te često postiže bolje rezultate nego modeli koji se treniraju od nule te se zbog toga *transfer learning* danas smatra jednim od ključnih pristupa u primjeni dubokog učenja u medicinskoj dijagnostici [11]

4.1. Transfer learning

Transfer learning je tehnika u strojnome učenju kod koje se znanje dobiveno treniranjem modela na jednom zadatku koristi za rješavanje nekog drugog, sličnog zadatka, odnosno umjesto da se model trenira od početka koristi se već trenirani model koji je tijekom prethodnog učenja već naučio neke opće značajke iz podataka. Ovakvim pristupom se značajno smanjuje vrijeme treniranja i potrebu za velikim količinama podataka [4].

Kod analize slike, duboke neuronske mreže koje su trenirane na velikim skupovima podataka obično nauče prepoznati osnovne vizualne značajke poput rubova, tekstura i jednostavnih oblika. Navedene značajke nisu vezane samo uz jedan specifičan problem, nego se mogu iskoristiti i u drugim zadacima, uključujući i medicinske slike, zbog čega se u praksi često koriste već pretrenirani modeli, koji služe kao početna točka za daljnje treniranje na novom skupu podataka [5]. Na slici 6 je prikazan koncept tehnike *transfer learning*.

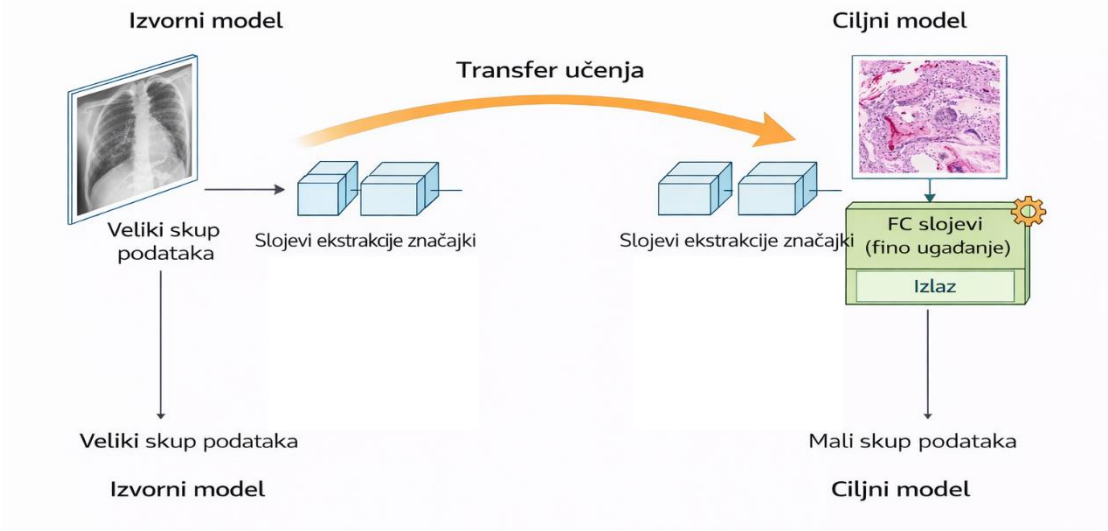

Slika 6 Prikaz *transfer learning* tehnike

Sam proces primjene *transfer learning* tehnike obično uključuje zamjenu završnih slojeva mreže sa novim koji su prilagođeni konkretnom zadatku kao što je klasifikacija. Ostali se slojevi mogu djelomično ili potpuno zamrznuti kako bi se zadržale prethodno naučene značajke, dok se novi slojevi treniraju na specifičnom skupu podataka te na taj način model zadržava korisne informacije naučene tijekom prethodnog treniranja, a istovremeno se prilagođava novom problemu [7].

U području medicinske analize slika *transfer learning* se pokazao iznimno učinkovitim, a posebno kod klasifikacije histopatoloških uzoraka. Velika prednost navedenog pristupa je postizanje dobrih rezultata čak i kada su dostupni skupovi podataka mali, što je čest slučaj u medicinskim istraživanjima [5].

4.2. Pretrenirani modeli

Pretrenirani modeli su neuronske mreže koje su već unaprijed trenirane na velikim skupovima podataka prije nego što se koriste za neki određeni zadatak. U računalnom vidu najčešće se koriste modeli trenirani na *ImageNet* skupu podataka, koji sadrži više od milijun označenih slika iz velikog broja različitih kategorija. Tijekom tog početnog treniranja modeli nauče opće vizualne značajke, poput rubova, tekstura i oblika, koje se kasnije mogu iskoristiti i u drugim zadacima [4].

Kod primjene *transfer learninga* takav pretrenirani model koristi se kao polazna točka za rad na novom skupu podataka, a u praksi to znači da se većina slojeva zadrži, dok se zadnji sloj, onaj za klasifikaciju, zamjenjuje novim koji odgovara konkretnom zadatku. Na primjer, ako se radi klasifikacija histoloških slika, izlaz modela se prilagođava broju kategorija koje se žele razlikovati [5].

U nekim slučajevima slojevi modela mogu se zamrznuti (engl. *freeze*), što znači da se njihovi parametri ne mijenjaju tijekom treniranja na novom skupu podataka, a time se zadržavaju opće značajke naučene tijekom prethodnog treniranja. Alternativno, može se primijeniti postupak *fine-tuning*-a, pri kojem se određeni slojevi modela dodatno treniraju na novom skupu podataka kako bi se model bolje prilagodio specifičnom problemu [11].

4.3. Prednosti u medicinskim primjenama

Primjena *transfer learninga* u analizi medicinskih slika ima nekoliko važnih prednosti u odnosu na treniranje modela od početka, a jedna od glavnih je brža konvergencija tijekom treniranja. S obzirom da model već ima prethodno naučene značajke, učenje na novom skupu podataka kreće s boljim početnim parametrima, pa je potrebno manje vremena da se postignu dobri rezultati [5].

Još jedna bitna prednost je bolja generalizacija modela. Medicinski skupovi podataka često imaju ograničen broj uzoraka, što može dovesti do prenaučenosti. Korištenjem pretreniranih modela, koji su već naučili opće vizualne obrasce, može se postići stabilnije ponašanje modela i bolja sposobnost prepoznavanja uzoraka na novim, neviđenim podacima [4].

Također, *transfer learning* omogućuje učinkovit rad i s manjim skupovima podataka, što je iznimno važno u medicinskim istraživanjima. S obzirom da je prikupljanje i označavanje medicinskih podataka zahtjevno i vremenski intenzivno, ovaj pristup omogućuje razvoj kvalitetnih modela čak i kada nema puno dostupnih podataka [7].

Zahvaljujući navedenim prednostima, *transfer learning* danas predstavlja jednu od najvažnijih tehnika u primjeni dubokog učenja u medicinskoj dijagnostici. Navedena metoda omogućuje razvoj preciznih modela za analizu medicinskih slika uz smanjene zahtjeve za podacima i računalnim resursima, što je posebno važno u medicinskim primjenama.

5. EKSPERIMENTALNA ANALIZA I REZULTATI

U ovom je poglavlju prikazan eksperimentalni dio rada u kojem su implementirani i uspoređeni modeli ResNet18 i EfficientNet-B0 kako bi se klasificirale histološke slike pomoću dvije klase. Cilj ovog eksperimenta je bio analizirati učinkovitost navedenih arhitektura na skupu podataka MHIST (*Minimalist Histopathology Image Dataset*) te usporediti njihove performanse koristeći standardne metrike klasifikacije.

Eksperimenti su provedeni u programskom jeziku *Python* koristeći biblioteku *PyTorch*, a treniranje modela provedeno je u okruženju *Google Colab* uz korištenje GPU akceleracije. Oba su modela trenirana pomoću pristupa *transfer learning*, pri čemu su korištene unaprijed trenirane težine modela koje su dobivene treniranjem na skupu podataka *ImageNet*.

Tijekom eksperimenta analizirane su slijedeće karakteristike modela: točnost klasifikacije, F1-mjera koja predstavlja mjeru ravnoteže između preciznosti i odziva modela, brzina konvergencije, odnosno vrijeme treniranja modela, broj parametara modela te memorijski zahtjevi tijekom treniranja.

5.1. Opis skupa podataka

U eksperimentalnom je dijelu korišten javno dostupan skup podataka MHIST koji je namijenjen istraživanjima u području klasifikacije histoloških slika debelog crijeva. Skup podataka sadrži ukupno 3152 histološke slike rezolucije 244×244 piksela koje su označene od strane stručnog patologa. Svaka od slika pripada jednoj od dvije moguće klase:

- HP (*Hyperplastic Polyp*) – benigni polipi koji u pravilu ne predstavljaju značajan rizik od razvoja raka
- SSA (*Sessile Serrated Adenoma*) – polipi koji mogu predstavljati prekancerozne lezije i povezani su s povećanim rizikom razvoja kolorektalnog karcinoma.

Oznake klasa su određene metodom većinskog glasanja (*majority vote*) između sedam patologa, pri čemu je za svaku sliku evidentiran broj stručnjaka koji su označili uzorak kao SSA. Na slici 7 se nalazi prikaz nekoliko primjera slika iz skupa podataka MHIST.

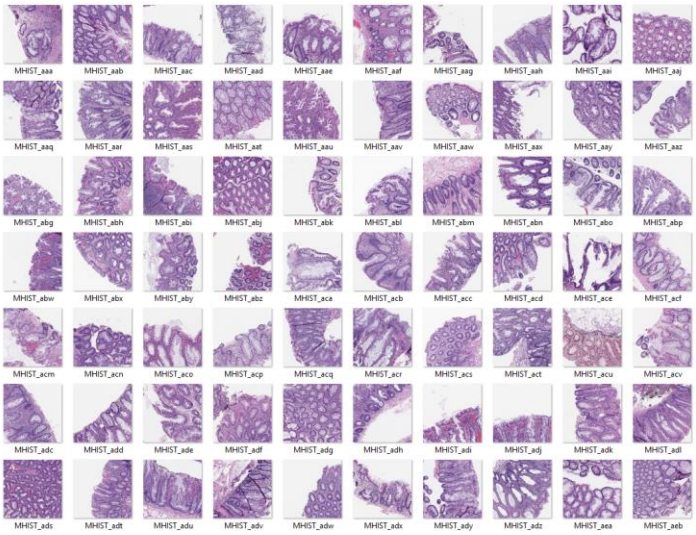

Slika 7 Primjeri uzoraka tkiva iz skupa podataka MHIST

Distribucija klasa u skupu podataka je slijedeća:

- HP: 2162 slike
- SSA: 990 slika,

Što ukazuje da skup podataka nije potpuno uravnotežen, odnosno broj primjera klase HP je znatno veći od broja primjera klase SSA. Skup podataka također već sadrži unaprijed definiranu podjelu na skup za treniranje i testiranje od kojih su 2175 slika namijenjene za treniranje, a ostatak, 977 slika je namijenjen za testiranje. Kako bi se omogućila procjena performansi modela tijekom treniranja, skup za treniranje je dodatno podijeljen na skup za treniranje i validaciju koristeći stratificiranu podjelu podataka, pri čemu je 20% uzoraka odvojeno za validacijski skup, što je omogućilo sljedeću raspodjelu:

- Skup za treniranje: 1740 slika
- Skup za validaciju: 435 slika
- Skup za testiranje: 977 slika.

Sve slike prije treniranja modela su skalirane na dimenziju 224×224 piksela, što zapravo i odgovara ulaznim dimenzijama modela treniranih na skupu podataka *ImageNet*. Kako bi se povećala robusnost modela i smanjio rizik od prenaučenosti, tijekom treniranja primijenjene su osnovne metode augmentacije podataka, uključujući horizontalno preslikavanje i male rotacije slike. Za vrednovanje modela korištene su standardne metrike klasifikacije; točnost klasifikacije i F1-mjera koje omogućuju procjenu ukupne uspješnosti modela te ravnoteže između preciznosti i odziva klasifikacije.

5.2. Implementacija modela

Za eksperimentalni dio rada implementirana su dva duboka konvolucijska modela, ResNet18 i EfficientNet-B0. Oba modela implementirana su pomoću biblioteke *PyTorch*, a pri treniranju su korištene unaprijed trenirane težine dobivene treniranjem na velikom skupu podataka *ImageNet*, a taj se pristup naziva *transfer learning*. On omogućuje učinkovitije treniranje modela na manjim skupovima podataka, kakvi su često prisutni u medicinskim istraživanjima. Prilikom implementacije korišteni su već dostupni modeli iz biblioteke *torchvision.models*, a s obzirom da su izvorne verzije tih modela trenirane za klasifikaciju na 1000 različitih klasa, bilo je potrebno prilagoditi završni klasifikacijski sloj kako bi odgovarao zadatku binarne klasifikacije.

Kod modela ResNet18 promijenjen je završni potpuno povezani sloj (engl. *fully connected layer*). Originalni izlazni sloj zamijenjen je novim linearnim slojem s dvije izlazne jedinice, koje predstavljaju dvije klase u skupu podataka MHIST: HP i SSA. Na taj je način model prilagođen zadatku klasifikacije histoloških slika u dvije kategorije. Kod modela EfficientNet-B0 izmijenjen je završni klasifikacijski sloj unutar *classifier* modula. Slično kao i kod modela ResNet18, originalni izlazni sloj zamijenjen je novim linearnim slojem s dvije izlazne jedinice, čime je model također prilagođen binarnoj klasifikaciji. Za treniranje oba modela korištena je funkcija gubitka *CrossEntropyLoss*, koja se često koristi kod klasifikacijskih zadataka u dubokom učenju. Za optimizaciju parametara modela primijenjen je Adam optimizator s početnom stopom učenja od 0,0001. Tijekom treniranja korišten je *batch size* od 32 uzorka, a modeli su trenirani kroz ukupno 10 epoha. Tijekom svake epohe izračunavane su metrike uspješnosti na skupu za treniranje i validaciju. Praćene su vrijednosti funkcije gubitka, točnost klasifikacije te F1-mjere. Kako bi se dobio što stabilniji model, tijekom treniranja pohranjivane su težine modela koje su ostvarile najbolju vrijednost validacije F1-mjere, a nakon završetka treniranja, verzija modela s najboljim rezultatom na validacijskom skupu korištena je za evaluaciju na test skupu podataka te je na taj način omogućena objektivna procjena performansi modela na podacima koje model prethodno nije vidio.

5.3. Analiza učinkovitosti

U ovom dijelu rada je provedena analiza učinkovitosti modela ResNet18 i EfficientNet-B0 na skupu podataka MHIST. Usporedba je provedena na temelju nekoliko kriterija kao što su točnost klasifikacije, F1-mjera, brzina treniranja, broj parametara modela te memorijski zahtjevi. Rezultati modela na testnom skupu prikazani su na slici 8 usporedbe modela.

	Model	Test Accuracy	Test F1-score	Training Time (s)	Trainable Parameters	GPU Memory Allocated (MB)	GPU Memory Reserved (MB)
0	ResNet18	0.821904	0.745614	537.829041	11177538	942.88	1240.0
1	EfficientNet-B0	0.839304	0.772134	156.216298	4010110	3058.80	3450.0

Slika 8 Usporedba ResNet i EfficientNet arhitekture

Model EfficientNet-B0 ostvario je bolje rezultate u odnosu na model ResNet18 u pogledu metrika točnosti i F1-mjere. EfficientNet-B0 postigao je točnost od približno 0.84, dok je ResNet18 ostvario točnost od približno 0.82. Slično tome, EfficientNet-B0 ostvario je F1-mjeru od oko 0.77, dok je ResNet18 postigao F1-mjeru od oko 0.75. Analiza brzine treniranja pokazuje jasnu razliku između ova dva modela. Model EfficientNet-B0 trenirao se znatno brže te je ukupno vrijeme treniranja iznosilo oko 156 sekundi, dok je s druge strane, modelu ResNet18 za treniranje je bilo potrebno približno 538 sekundi. Na temelju navedenog može se zaključiti da je u ovom eksperimentalnom okruženju EfficientNet-B0 arhitektura računalno učinkovitija u odnosu na ResNet18.

Usporedba broja parametara također pokazuje vidljivu razliku između modela. Model ResNet18 ima približno 11,2 milijuna trenirajućih parametara, dok model EfficientNet-B0 sadrži oko 4,0 milijuna parametara, što nam ukazuje da unatoč znatno manjem broju parametara, EfficientNet-B0 postiže bolje rezultate, što prikazuje bolju učinkovitost ove arhitekture, odnosno dobar odnos između složenosti modela i postignute točnosti. Analiza memorijskih zahtjeva pokazuje da je tijekom treniranja model EfficientNet-B0 koristio više GPU memorije u odnosu na model ResNet18. U provedenom eksperimentu maksimalna zauzeta GPU memorija kod ResNet modela iznosila je približno 943 MB, a kod EfficientNet-B0 modela iskorišteno je oko 3059 MB. Navedena se razlika može objasniti razlikama u arhitekturi modela, ali i samim načinom na koji su pojedini slojevi implementirani unutar biblioteke *PyTorch*.

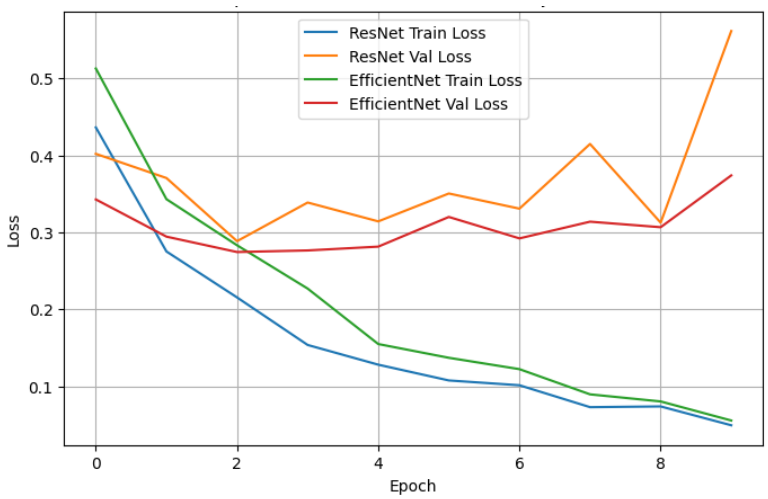

Slika 9 Usporedba vrijednosti funkcije gubitka na skupu za učenje i validaciju

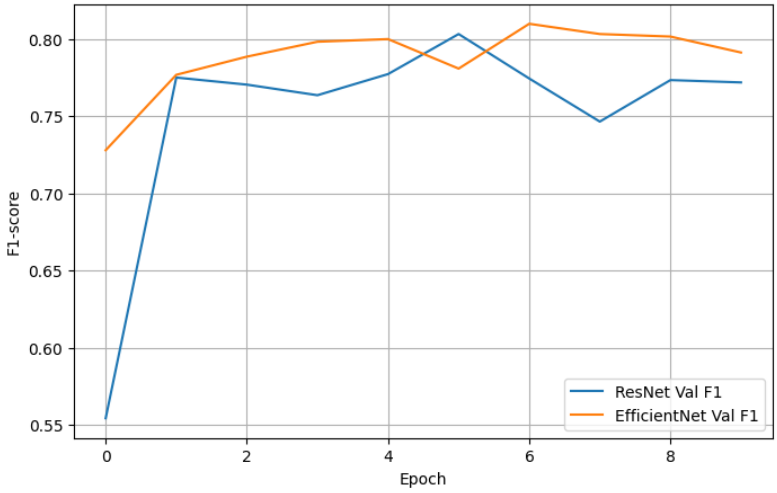

Slika 10 Usporedba vrijednosti F1-mjere na validacijskom skupu

Promatrajući grafove koji se nalaze na slikama 9 i 10, promjene funkcije gubitka kroz epohe može se vidjeti da gubitak na skupu za treniranje kod oba modela postupno opada tijekom treniranja, što ukazuje na to da modeli uspješno uče obrasce iz podataka. No, kod modela ResNet18 može se primijetiti blagi porast gubitka na skupu za validaciju vrijednosti u kasnijim epohama, što može upućivati na pojavu prenaučenosti, dok je kod modela EfficientNet-B0 taj je efekt manje izražen, a vrijednosti gubitka na skupu za treniranje pokazuju stabilnije ponašanje tijekom samog treniranja. Grafovi promjene validacije F1-mjere dodatno potvrđuju ovu razliku, jer EfficientNet-B0 postiže stabilnije i nešto bolje vrijednosti F1-mjere kroz epohe, dok ResNet18 pokazuje veće promjene tijekom treniranja.

Na temelju dobivenih rezultata može se zaključiti da se model EfficientNet-B0 pokazao prikladnijim za zadatak klasifikacije histoloških slika u provedenom eksperimentu. Ovaj model postiže bolje klasifikacijske rezultate, trenira se brže te ima manji broj parametara u odnosu na model ResNet18. No, ipak, tijekom treniranja zahtijeva nešto više GPU memorije.

6. ZAKLJUČAK

U ovom je radu analizirana primjena dubokog učenja za klasifikaciju histoloških slika korištenjem konvolucijskih neuronskih mreža. U eksperimentalnom dijelu implementirana su dva modela dubokog učenja, a to su ResNet18 i EfficientNet-B0, s ciljem klasifikacije histoloških slika iz skupa podataka MHIST u dvije klase: HP i SSA. Modeli su trenirani primjenom pristupa *transfer learning*, pri čemu se korištene unaprijed trenirane težine dobivene treniranjem na skupu podatka *ImageNet*. Tijekom eksperimenta je analizirana učinkovitost modela prema nekoliko kriterija, uključujući točnost klasifikacije, F1-mjeru, brzinu treniranja, broj parametara te memorijske zahtjeve.

Rezultati eksperimentalne analize su pokazali da oba modela postižu dobre rezultate u zadatku klasifikacije histoloških slika, no ipak je model EfficientNet-B0 ostvario bolje performanse u usporedbi s modelom ResNet18. EfficientNet-B0 je postigao veću točnost i višu F1-mjeru na skupu podataka za testiranje, a i ujedno se trenirano znano brže. Također, navedeni model ima i manji broj parametara u odnosu na ResNet18, što upućuje na veću učinkovitost same arhitekture EfficientNet-B0 modela. No, model ResNet18 pokazao je manje memorijske zahtjeve tijekom treniranja. Na temelju dobivenih rezultata može se zaključiti da se EfficientNet-B0 pokazao prikladnijim modelom za zadatak klasifikacije histoloških slika u ovom radu, jer postiže bolju ravnotežu između točnosti klasifikacije, brzine treniranja i složenosti modela.

Kao mogući smjerovi daljnjeg istraživanja mogu se navesti korištenje većih i raznovrsnijih skupova podataka, proširenje samog zadatka klasifikacije na veći broj klasa te primjena drugih modernih arhitektura dubokog učenja poput *Vision Transformer* modela ili drugih naprednijih varijanti EfficientNet arhitekture. Također, buduća istraživanja mogu uključiti detaljniju optimizaciju hiperparametara i primjenu naprednijih metoda augmentacije podataka kako bi se dodatno poboljšale performanse modela.

7. LITERATURA

[1] Associate Professor, Department of Anatomy, Sri Ramachandra Medical College & Research Institute (SRMC & RI), Sri Ramachandra Institute for Higher Education and Research (SRIHER), Chennai, Tamil Nadu, India., M. Haripriya, Sharad Gavhane, Medical officer Department of General Medicine, Symbiosis Medical College and hospital (SUHRC), Symbiosis International (Deemed) University (SIU) Pune, Maharashtra, India., K.Vijayakumar, Assistant Professor, Department of Anatomy, Symbiosis Medical College for Women & Symbiosis University Hospital and Research Centre, Symbiosis International (Deemed University), Pune, India., „Automated Classification of Normal Histological Tissues Using Convolution neural network: A ResNet-50-Based Educational Tool“, *Int. J. Anat. Res.*, izd. 3, sv. 13, str. 9306–9313, ruj. 2025.

[2] V., TRIVEDI, S., BHAVSAR, K., PARIKH, S., PATEL, J., TEJAS PATEL, „Medical Image Classification using Transfer Learning“, *Int. J. Res. Publ. Rev.*, izd. 10, sv. 6, str. 538–544, 2025.

[3] Abhishek *i sur.*, „Classification of Colorectal Cancer using ResNet and EfficientNet Models“, *Open Biomed. Eng. J.*, izd. 1, sv. 18, str. e18741207280703, sij. 2024.

[4] L., Alzubaidi *i sur.*, „Novel Transfer Learning Approach for Medical Imaging with Limited Labeled Data“, *Cancers*, izd. 7, sv. 13, str. 1590, ožu. 2021.

[5] H. S., ALGhafri, C. S., Lim, „Fine-Tuning Models for Histopathological Classification of Colorectal Cancer“, *Diagnostics*, izd. 15, sv. 15, str. 1947, kol. 2025.

[6] A., Suriawinata *i sur.*, „MHIST: A Minimalist Histopathology Image Analysis Dataset“. .

[7] S., Eskandari, A., Eslamian, Q., Cheng, „Comparative Analysis of Transfer Learning Models for Breast Cancer Classification“, 2024.

[8] M. A., Kalati, H., Shabani, M. S., Maghareh, Z., Barzegar, R., Lashgari, „Classification and Interpretation of Histopathology Images: Leveraging Ensemble of EfficientNetV1 and EfficientNetV2 Models“. In Review, 19-velj-2025.

[9] K., He, X., Zhang, S., Ren, J., Sun, „Deep Residual Learning for Image Recognition“. arXiv, 10-pros-2015.

[10] M., Tan, Q. V., Le, „EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks“, 2019.

[11] Y., Sharma, L., Ehsan, S., Syed, D. E., Brown, „HistoTransfer: Understanding Transfer Learning for Histopathology“. arXiv, 13-lip-2021.